

# AI-Claim Audit for Robust Vision on CIFAR-10-C

用實驗檢查 AI 對模型穩健性的解釋

學生姓名：\_\_\_\_\_ 學號：\_\_\_\_\_

Code and evidence repository: <https://github.com/ron941/mils-ai-claim-audit-cifar10c>

## 摘要

本報告審核 AI 對 vision model robustness 的解釋是否可靠。我們先讓 AI 針對 corruption / distribution shift 下的失敗模式提出五個 claims，再改寫為可檢驗假說，並使用 CIFAR-10-C、兩個 pretrained models 與多種 robustness measures 驗證。實驗比較 RobustBench Standard model 與 Hendrycks2020AugMix\_WRN 在 Gaussian noise、motion blur、fog、contrast 與 JPEG compression 下的表現。結果顯示，C1 與 C3 被支持，C2、C4 與 C5 只被部分支持，說明 AI 的通用直覺可作為假說來源，但最終結論仍須由 evidence 決定。

## 1. Problem Setting

本作業的核心不是追求最高分類準確率，而是檢查 AI 對模型穩健性失敗模式的解釋是否能被實驗證據支持。本報告採用 AI-Claim Audit 流程：先由 AI 產生五個 robustness failure claims，再將 claims 改寫為可檢驗假說，最後用表格、圖表與 failure cases 審核。

本實驗聚焦 CIFAR-10-C，觀察 pretrained vision models 在不同 corruption 與 severity 下的表現。主要問題是：AI 是否能正確預測模型在 noise、blur、weather-like corruption、digital corruption 與 high-severity conditions 下的失敗模式？

## 2. Experimental Setup

| 項目                 | 設定                                                           |
|--------------------|--------------------------------------------------------------|
| Clean dataset      | CIFAR-10 test set                                            |
| Shifted dataset    | CIFAR-10-C                                                   |
| Corruptions        | gaussian noise, motion blur, fog, contrast, JPEG compression |
| Severity           | 1, 3, 5                                                      |
| Standard model     | RobustBench Standard                                         |
| Robust model       | Hendrycks2020AugMix_WRN                                      |
| No-training method | Test-Time Augmentation (TTA)                                 |

表 1。資料集、模型與評估設定。

所有模型皆在相同 samples 與相同 corruption conditions 下評估，避免模型比較受到資料抽樣差異影響。本實驗不重新訓練模型，只進行 inference、evaluation 與 audit。完整數值結果另附於 results.csv、results\_tta.csv、failure\_overlap.csv 與 claim\_audit.csv；報告中的主要結論皆可由這些表格與圖表對應驗證。

Clean CIFAR-10



Gaussian noise s5



Motion blur s5



Fog s5



JPEG s5



圖 A。CIFAR-10-C 退化影像範例。此圖展示同一張 clean CIFAR-10 automobile 影像，以及四種 severity 5 corruption。Clean 圖仍然是 CIFAR-10 原始的 32×32 低解析影像，但沒有加入人工退化；Gaussian noise 會加入高頻雜訊，motion blur 會模糊局部邊緣，fog 會降低可見度，JPEG compression 則會產生壓縮失真。

### 3. Robustness Measures

本報告使用 Accuracy Drop 與 Relative Drop 作為主要 robustness measures，並使用 Wrong Confidence、Prediction Entropy 與 Failure Overlap 作為輔助分析指標。

| Measure            | Definition                                                                                  | Purpose                                    |
|--------------------|---------------------------------------------------------------------------------------------|--------------------------------------------|
| Accuracy Drop      | $\text{AccDrop}(c) = \text{Acc}(\text{clean}) - \text{Acc}(c)$                              | 衡量 corruption condition c 造成的 accuracy 下降。 |
| Relative Drop      | $\text{RelDrop}(c) = [\text{Acc}(\text{clean}) - \text{Acc}(c)] / \text{Acc}(\text{clean})$ | 衡量相對於 clean accuracy 的下降比例。                |
| Wrong Confidence   | mean max softmax probability on wrong samples                                               | 衡量模型答錯時是否仍高度自信。                            |
| Prediction Entropy | $H(p) = -\sum p_i \log(p_i)$                                                                | 衡量模型輸出分布的不確定性。                             |
| Failure Overlap    | # both wrong / # either wrong                                                               | 衡量兩個模型是否錯在同一批樣本。                           |

表 2。本報告使用的 robustness measures。

### 4. AI Claims and Testable Hypotheses

表 3 整理本報告審核的五個 AI claims、可檢驗假說、使用的 evidence 與最終 audit decision。

| ID | AI Claim                                          | Testable Hypothesis                                                           | Evidence                     | Decision            |
|----|---------------------------------------------------|-------------------------------------------------------------------------------|------------------------------|---------------------|
| C1 | CNN 對 Gaussian noise 比 motion blur 更脆弱。           | 同 severity 下，standard model 的 Gaussian noise accuracy drop 大於 motion blur。    | Fig. 2 / results.csv         | Supported           |
| C2 | Robust model 對 noise 較穩，但對 JPEG compression 可能破功。 | Robust model 在 Gaussian noise 下 relative drop 較小，但在 JPEG compression 下不一定有優勢。 | Fig. 3 / results.csv         | Partially supported |
| C3 | Corruption 下模型可能 confidently wrong。               | 錯誤樣本平均 confidence 仍偏高，且存在 high-confidence failure cases。                      | Fig. 4 / failure_cases.csv   | Supported           |
| C4 | TTA 可能改善 worst-case，但可能犧牲 clean accuracy。         | TTA 後 worst-condition accuracy 上升，但 clean accuracy 可能下降。                      | Fig. 5 / results_tta.csv     | Partially supported |
| C5 | 高 severity 下不同模型更容易錯在同一批樣本。                       | Severity 5 的 failure overlap 高於 severity 1。                                   | Fig. 6 / failure_overlap.csv | Partially supported |

表 3。AI claims、可檢驗假說、evidence 與 audit decisions。

## 5. Results and Claim Audit

### 5.1 Overall Robustness

圖 1 顯示兩個模型在 clean 與 corrupted conditions 下的 accuracy。整體而言，robust AugMix-WRN 在多數 corruption 下都明顯優於 standard model，尤其在 Gaussian noise 與 fog 等嚴重 distribution shift 下差距更明顯。




圖 1。不同 corruption 與 severity 下的模型 accuracy。

## 5.2 C1: Gaussian Noise vs. Motion Blur

C1 被支持。圖 2 顯示 standard model 在 Gaussian noise 下的 accuracy drop 明顯大於 motion blur，且 severity 越高差距越大。Severity 5 時，Gaussian noise 的 accuracy drop 約 0.67，而 motion blur 約 0.30，表示高頻局部雜訊對 standard CNN 的破壞更嚴重。




圖 2。Gaussian noise 與 motion blur 的 accuracy drop 比較。

## 5.3 C2: Robust Model and JPEG Compression

C2 只被部分支持。圖 3 顯示 robust AugMix-WRN 在 Gaussian noise 下比 standard model 穩定：standard 的 mean relative drop 約 0.49，而 robust 約 0.15。然而，「robust model 對 JPEG compression 可能破功」沒有被支持，因為 robust model 在 JPEG compression 下仍有較小 relative drop，約 0.07，低於 standard 的約 0.18。




圖 3。Standard model 與 robust model 的 relative drop 比較。

#### 5.4 C3: High-confidence Wrong Predictions

C3 被支持。圖 4 顯示兩個模型在錯誤預測時仍維持偏高 confidence。Standard model 的 wrong confidence 多數約 0.83–0.87，robust AugMix-WRN 也約 0.73–0.78。這表示模型在 corrupted images 上不是單純變得不確定，而是可能產生 high-confidence wrong predictions。




圖 4。模型錯誤預測時的平均 confidence。

#### 5.5 C4: Test-Time Augmentation

C4 只被部分支持。圖 5 顯示 TTA 對 worst-condition accuracy 有小幅改善：standard 從約 0.2768 提升到 0.2789；robust AugMix-WRN 從約 0.7123 提升到 0.7257。然而，本實驗沒有觀察到 clean accuracy 下降，反而兩個模型皆小幅提升，因此「TTA 的隱形代價」未被支持。




圖 5。TTA 前後的 clean accuracy 與 worst-condition accuracy。

## 5.6 C5: Failure Overlap under High Severity

C5 只被部分支持。圖 6 顯示 Gaussian noise 與 fog 的 failure overlap 會隨 severity 上升，但 motion blur 與 JPEG compression 沒有一致上升趨勢。平均而言，severity 5 的 overlap 略高於 severity 1，但趨勢不穩定，因此不能說所有高 severity corruption 都會讓不同模型錯在同一批樣本。




圖 6。不同 severity 下兩個模型的 failure overlap。

## 6. Failure Case Analysis

本報告從 failure\_cases.csv 選取 high-confidence wrong examples，並在圖 7 中嵌入五個代表性失敗案例。這些案例包含 true label、prediction、confidence、corruption 與 severity。整體來看，Gaussian noise 會產生誤導性的高頻紋理，fog 會降低物體可見度，而 motion blur 會造成局部特徵失真。這些案例也呼應 C3：模型在 corruption 下可能不是低信心地失敗，而是以很高 confidence 做出錯誤判斷。

| Case | Model    | Corruption  | Sev. | True / Pred. | Conf.   | Explanation           |
|------|----------|-------------|------|--------------|---------|-----------------------|
| 1    | standard | motion_blur | 3    | dog / cat    | 1.00000 | blurred local details |

|   |          |                |   |                   |         |                                 |
|---|----------|----------------|---|-------------------|---------|---------------------------------|
| 2 | standard | motion_blur    | 5 | dog / cat         | 1.00000 | blurred local details           |
| 3 | standard | fog            | 5 | frog / cat        | 1.00000 | reduced visibility              |
| 4 | robust   | gaussian_noise | 5 | airplane / frog   | 0.99999 | misleading high-frequency noise |
| 5 | robust   | gaussian_noise | 3 | automobile / frog | 0.99999 | misleading high-frequency noise |

表 4。從 failure\_cases.csv 選出的代表性高信心錯誤案例；對應影像已整理於圖 7。



圖 7。五個代表性的高信心錯誤預測案例。這些影像對應表 4 的五個案例，使 C3 不只由表格支持，也能直接透過影像檢查。

## 7. AI Collaboration Reflection

在本作業中，我使用 Gemini 產生初始 robustness claims，並使用 ChatGPT 協助整理實驗流程、pipeline 與報告架構。之後我將 AI 的自然語言說法改寫成可檢驗假說，並用 results.csv、figures 與 failure cases 進行審核。這些工具有助於把模糊的 robustness intuition 轉換成可以被 accuracy drop、relative drop、wrong confidence 與 failure overlap 檢查的技術問題。

然而，AI 的直覺並不完全正確。例如，AI 預測 robust model 可能在 JPEG compression 下失去優勢，但實驗顯示 AugMix-WRN 在 JPEG compression 下仍比 standard model 穩定。AI 也預測 TTA 可能犧牲 clean accuracy，但本實驗中 clean accuracy 並未下降。因此，本報告沒有直接採用 AI 的說法作為結論，而是使用 results.csv、results\_tta.csv、failure\_overlap.csv、failure\_cases.csv 與圖表逐一審核每個 claim。

## 8. Conclusion

整體而言，五個 AI claims 中有兩個被支持，三個被部分支持。C1 與 C3 明確成立：Gaussian noise 比 motion blur 更嚴重破壞 standard model，且模型在 corruption 下可能出現高信心錯誤。C2、C4、C5 則需要修正：robust AugMix-WRN 並未在 JPEG compression 下破功，TTA 也沒有造成 clean accuracy 下降，而 failure overlap 只在部分 corruption 中隨 severity 上升。這說明 AI 的通用直覺有參考價值，但仍必須透過具體 evidence 進行審核。