

AI-Claim Audit for Robust Vision on CIFAR-10-C

用實驗檢查 AI 對模型穩健性的解釋

學生姓名：_____ 學號：_____

Code and evidence repository: <https://github.com/ron941/mils-ai-claim-audit-cifar10c>

摘要

本報告審核 AI 對 vision model robustness 的解釋是否可靠。我們先讓 AI 針對 corruption / distribution shift 下的失敗模式提出五個 claims，再改寫為可檢驗假說，並使用 CIFAR-10-C、兩個 pretrained models 與多種 robustness measures 驗證。實驗比較 RobustBench Standard model 與 Hendrycks2020AugMix_WRN 在 Gaussian noise、motion blur、fog、contrast 與 JPEG compression 下的表現。結果顯示，C1 與 C3 被支持，C2、C4 與 C5 只被部分支持，說明 AI 的通用直覺可作為假說來源，但最終結論仍須由 evidence 決定。

1. Problem Setting

本作業的核心不是追求最高分類準確率，而是檢查 AI 對模型穩健性失敗模式的解釋是否能被實驗證據支持。本報告採用 AI-Claim Audit 流程：先由 AI 產生五個 robustness failure claims，再將 claims 改寫為可檢驗假說，最後用表格、圖表與 failure cases 審核。

本實驗聚焦 CIFAR-10-C，觀察 pretrained vision models 在不同 corruption 與 severity 下的表現。主要問題是：AI 是否能正確預測模型在 noise、blur、weather-like corruption、digital corruption 與 high-severity conditions 下的失敗模式？

2. Experimental Setup

項目	設定
Clean dataset	CIFAR-10 test set
Shifted dataset	CIFAR-10-C
Corruptions	gaussian noise, motion blur, fog, contrast, JPEG compression
Severity	1, 3, 5
Standard model	RobustBench Standard
Robust model	Hendrycks2020AugMix_WRN
No-training method	Test-Time Augmentation (TTA)

表 1。資料集、模型與評估設定。

所有模型皆在相同 samples 與相同 corruption conditions 下評估，避免模型比較受到資料抽樣差異影響。本實驗不重新訓練模型，只進行 inference、evaluation 與 audit。完整數值結果另附於 results.csv、results_tta.csv、failure_overlap.csv 與 claim_audit.csv；報告中的主要結論皆可由這些表格與圖表對應驗證。

Clean CIFAR-10



Gaussian noise s5



Motion blur s5



Fog s5



JPEG s5



圖 A。CIFAR-10-C 退化影像範例。此圖展示同一張 clean CIFAR-10 automobile 影像，以及四種 severity 5 corruption。Clean 圖仍然是 CIFAR-10 原始的 32×32 低解析影像，但沒有加入人工退化；Gaussian noise 會加入高頻雜訊，motion blur 會模糊局部邊緣，fog 會降低可見度，JPEG compression 則會產生壓縮失真。

3. Robustness Measures

本報告使用 Accuracy Drop 與 Relative Drop 作為主要 robustness measures，並使用 Wrong Confidence、Prediction Entropy 與 Failure Overlap 作為輔助分析指標。

Measure	Definition	Purpose
Accuracy Drop	$\text{AccDrop}(c) = \text{Acc}(\text{clean}) - \text{Acc}(c)$	衡量 corruption condition c 造成的 accuracy 下降。
Relative Drop	$\text{RelDrop}(c) = [\text{Acc}(\text{clean}) - \text{Acc}(c)] / \text{Acc}(\text{clean})$	衡量相對於 clean accuracy 的下降比例。
Wrong Confidence	mean max softmax probability on wrong samples	衡量模型答錯時是否仍高度自信。
Prediction Entropy	$H(p) = -\sum p_i \log(p_i)$	衡量模型輸出分布的不確定性。
Failure Overlap	# both wrong / # either wrong	衡量兩個模型是否錯在同一批樣本。

表 2。本報告使用的 robustness measures。

4. AI Claims and Testable Hypotheses

表 3 整理本報告審核的五個 AI claims、可檢驗假說、使用的 evidence 與最終 audit decision。

ID	AI Claim	Testable Hypothesis	Evidence	Decision
C1	CNN 對 Gaussian noise 比 motion blur 更脆弱。	同 severity 下，standard model 的 Gaussian noise accuracy drop 大於 motion blur。	Fig. 2 / results.csv	Supported
C2	Robust model 對 noise 較穩，但對 JPEG compression 可能破功。	Robust model 在 Gaussian noise 下 relative drop 較小，但在 JPEG compression 下不一定有優勢。	Fig. 3 / results.csv	Partially supported
C3	Corruption 下模型可能 confidently wrong。	錯誤樣本平均 confidence 仍偏高，且存在 high-confidence failure cases。	Fig. 4 / failure_cases.csv	Supported
C4	TTA 可能改善 worst-case，但可能犧牲 clean accuracy。	TTA 後 worst-condition accuracy 上升，但 clean accuracy 可能下降。	Fig. 5 / results_tta.csv	Partially supported
C5	高 severity 下不同模型更容易錯在同一批樣本。	Severity 5 的 failure overlap 高於 severity 1。	Fig. 6 / failure_overlap.csv	Partially supported

表 3。AI claims、可檢驗假說、evidence 與 audit decisions。

5. Results and Claim Audit

5.1 Overall Robustness

圖 1 顯示兩個模型在 clean 與 corrupted conditions 下的 accuracy。整體而言，robust AugMix-WRN 在多數 corruption 下都明顯優於 standard model，尤其在 Gaussian noise 與 fog 等嚴重 distribution shift 下差距更明顯。




圖 1。不同 corruption 與 severity 下的模型 accuracy。

5.2 C1: Gaussian Noise vs. Motion Blur

C1 被支持。圖 2 顯示 standard model 在 Gaussian noise 下的 accuracy drop 明顯大於 motion blur，且 severity 越高差距越大。Severity 5 時，Gaussian noise 的 accuracy drop 約 0.67，而 motion blur 約 0.30，表示高頻局部雜訊對 standard CNN 的破壞更嚴重。




圖 2。Gaussian noise 與 motion blur 的 accuracy drop 比較。

5.3 C2: Robust Model and JPEG Compression

C2 只被部分支持。圖 3 顯示 robust AugMix-WRN 在 Gaussian noise 下比 standard model 穩定：standard 的 mean relative drop 約 0.49，而 robust 約 0.15。然而，「robust model 對 JPEG compression 可能破功」沒有被支持，因為 robust model 在 JPEG compression 下仍有較小 relative drop，約 0.07，低於 standard 的約 0.18。




圖 3。Standard model 與 robust model 的 relative drop 比較。

5.4 C3: High-confidence Wrong Predictions

C3 被支持。圖 4 顯示兩個模型在錯誤預測時仍維持偏高 confidence。Standard model 的 wrong confidence 多數約 0.83–0.87，robust AugMix-WRN 也約 0.73–0.78。這表示模型在 corrupted images 上不是單純變得不確定，而是可能產生 high-confidence wrong predictions。




圖 4。模型錯誤預測時的平均 confidence。

5.5 C4: Test-Time Augmentation

C4 只被部分支持。圖 5 顯示 TTA 對 worst-condition accuracy 有小幅改善：standard 從約 0.2768 提升到 0.2789；robust AugMix-WRN 從約 0.7123 提升到 0.7257。然而，本實驗沒有觀察到 clean accuracy 下降，反而兩個模型皆小幅提升，因此「TTA 的隱形代價」未被支持。




圖 5。TTA 前後的 clean accuracy 與 worst-condition accuracy。

5.6 C5: Failure Overlap under High Severity

C5 只被部分支持。圖 6 顯示 Gaussian noise 與 fog 的 failure overlap 會隨 severity 上升，但 motion blur 與 JPEG compression 沒有一致上升趨勢。平均而言，severity 5 的 overlap 略高於 severity 1，但趨勢不穩定，因此不能說所有高 severity corruption 都會讓不同模型錯在同一批樣本。




圖 6。不同 severity 下兩個模型的 failure overlap。

6. Failure Case Analysis

本報告從 failure_cases.csv 選取 high-confidence wrong examples，並在圖 7 中嵌入五個代表性失敗案例。這些案例包含 true label、prediction、confidence、corruption 與 severity。整體來看，Gaussian noise 會產生誤導性的高頻紋理，fog 會降低物體可見度，而 motion blur 會造成局部特徵失真。這些案例也呼應 C3：模型在 corruption 下可能不是低信心地失敗，而是以很高 confidence 做出錯誤判斷。

Case	Model	Corruption	Sev.	True / Pred.	Conf.	Explanation
1	standard	motion_blur	3	dog / cat	1.00000	blurred local details

2	standard	motion_blur	5	dog / cat	1.00000	blurred local details
3	standard	fog	5	frog / cat	1.00000	reduced visibility
4	robust	gaussian_noise	5	airplane / frog	0.99999	misleading high-frequency noise
5	robust	gaussian_noise	3	automobile / frog	0.99999	misleading high-frequency noise

表 4。從 failure_cases.csv 選出的代表性高信心錯誤案例；對應影像已整理於圖 7。



圖 7。五個代表性的高信心錯誤預測案例。這些影像對應表 4 的五個案例，使 C3 不只由表格支持，也能直接透過影像檢查。

7. AI Collaboration Reflection

在本作業中，我使用 Gemini 產生初始 robustness claims，並使用 ChatGPT 協助整理實驗流程、pipeline 與報告架構。之後我將 AI 的自然語言說法改寫成可檢驗假說，並用 results.csv、figures 與 failure cases 進行審核。這些工具有助於把模糊的 robustness intuition 轉換成可以被 accuracy drop、relative drop、wrong confidence 與 failure overlap 檢查的技術問題。

然而，AI 的直覺並不完全正確。例如，AI 預測 robust model 可能在 JPEG compression 下失去優勢，但實驗顯示 AugMix-WRN 在 JPEG compression 下仍比 standard model 穩定。AI 也預測 TTA 可能犧牲 clean accuracy，但本實驗中 clean accuracy 並未下降。因此，本報告沒有直接採用 AI 的說法作為結論，而是使用 results.csv、results_tta.csv、failure_overlap.csv、failure_cases.csv 與圖表逐一審核每個 claim。

8. Conclusion

整體而言，五個 AI claims 中有兩個被支持，三個被部分支持。C1 與 C3 明確成立：Gaussian noise 比 motion blur 更嚴重破壞 standard model，且模型在 corruption 下可能出現高信心錯誤。C2、C4、C5 則需要修正：robust AugMix-WRN 並未在 JPEG compression 下破功，TTA 也沒有造成 clean accuracy 下降，而 failure overlap 只在部分 corruption 中隨 severity 上升。這說明 AI 的通用直覺有參考價值，但仍必須透過具體 evidence 進行審核。

附錄：實驗結果摘要

本附錄整理正文結論所依據的關鍵實驗數據。由於校內提交系統要求不要另外上傳 code 執行產物，本報告僅將必要結果摘要嵌入文件；完整 CSV 與可重跑程式碼保留於 GitHub repository。

A. Claim audit 摘要

Claim	判定	關鍵 evidence 摘要
C1	支持	Standard 在 3/3 個 severity 中，Gaussian noise 的 accuracy drop 都高於 motion blur。
C2	部分支持	AugMix-WRN 的 Gaussian mean relative drop 較低 (0.151 vs 0.491)；但 JPEG 也較低 (0.073 vs 0.177)，因此「JPEG 不一定有優勢」只部分成立。
C3	支持	選出的 corruption failure cases 中最高錯誤信心為 1.000，證明 high-confidence wrong prediction 存在。
C4	部分支持	TTA 改善 worst-condition accuracy，但 clean accuracy 沒有下降，因此雙刀劍說法只部分成立。
C5	部分支持	Severity 5 的平均 failure overlap 高於 severity 1，但只有 2/5 corruption 呈現一致上升。

附錄表 A1。五個 AI claims 的審核結果與主要 evidence。

B. 主要 accuracy 結果

模型	條件	Severity	Accuracy	Acc. drop	Relative drop	Wrong conf.
Standard	Clean	-	0.9477	-	-	-
Robust AugMix-WRN	Clean	-	0.9508	-	-	-
Standard	Gaussian noise	5	0.2768	0.6709	0.7079	0.8797
Standard	Motion blur	5	0.6524	0.2953	0.3116	0.8545
Standard	Fog	5	0.7400	0.2077	0.2192	0.8522
Standard	Contrast	5	0.5329	0.4148	0.4377	0.8219
Standard	JPEG compression	5	0.6970	0.2507	0.2645	0.8297
Robust AugMix-WRN	Gaussian noise	5	0.7123	0.2385	0.2508	0.8012
Robust AugMix-WRN	Motion blur	5	0.8942	0.0566	0.0595	0.7593
Robust AugMix-WRN	Fog	5	0.8250	0.1258	0.1323	0.7749
Robust AugMix-WRN	Contrast	5	0.7905	0.1603	0.1686	0.7362
Robust AugMix-WRN	JPEG compression	5	0.8532	0.0976	0.1027	0.7411

附錄表 A2。Clean 與 severity 5 corruption 的主要 accuracy/drop 摘要。

C. TTA 與 failure overlap 摘要

模型	Clean before	Clean after	Delta	Worst before	Worst after	Delta
Standard	0.9477	0.9541	+0.0064	0.2768	0.2789	+0.0021
Robust AugMix-WRN	0.9508	0.9559	+0.0051	0.7123	0.7257	+0.0134

附錄表 A3。Test-time augmentation 前後的 clean 與 worst-condition accuracy。

Severity	Mean overlap/all	Mean overlap/error union	說明
1	0.0421	0.3182	最低 severity
3	0.0830	0.3086	中間 severity
5	0.1527	0.3350	最高 severity；平均 overlap 略高於 severity 1

附錄表 A4。不同 severity 下的平均 failure overlap。

D. High-confidence failure cases

模型	Corruption	Severity	True label	Pred label	Confidence	Entropy
Robust AugMix-WRN	Gaussian noise	5	0 airplane	6 frog	1.0000	1.64e-04
Robust AugMix-WRN	Gaussian noise	3	1 automobile	6 frog	1.0000	1.93e-04
Robust AugMix-WRN	Gaussian noise	5	3 cat	6 frog	1.0000	1.94e-04
Robust AugMix-WRN	Gaussian noise	5	9 truck	6 frog	1.0000	2.08e-04
Robust AugMix-WRN	Gaussian noise	5	5 dog	6 frog	1.0000	2.51e-04
Standard	Motion blur	3	5 dog	3 cat	1.0000	2.92e-07
Standard	Motion blur	3	6 frog	3 cat	1.0000	4.55e-07
Standard	Motion blur	5	5 dog	3 cat	1.0000	4.01e-07
Standard	Fog	3	5 dog	3 cat	1.0000	7.45e-07
Standard	Fog	5	6 frog	3 cat	1.0000	1.67e-06

附錄表 A5。輸出的 high-confidence wrong examples 摘要。